

Análisis Matemático para Inteligencia Artificial

Verónica Pastor (vpastor@fi.uba.ar),
Martín Errázquin (merrazquin@fi.uba.ar)

Especialización en Inteligencia Artificial

16/9/2022

Autovalores y Autovectores: Motivación

Se acuerdan cuando vimos formas cuadráticas:

$$\begin{bmatrix} x^T \\ x \end{bmatrix} \underbrace{\begin{bmatrix} 2 & 3 \\ 3 & 9 \end{bmatrix}}_{A} \begin{bmatrix} x \\ y \end{bmatrix} = 2x^2 + 6xy + 9y^2 > 0 \quad \forall (x, y) \neq 0$$

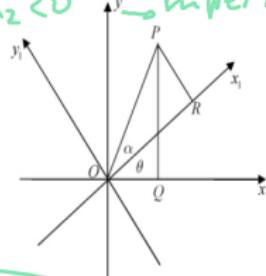
Si rotamos un ángulo θ

la figura dada por: $2x^2 + 6xy + 9y^2 = 1$

a la forma canónica, $\lambda_1 x_1^2 + \lambda_2 x_2^2 = 1$

Esto nos lleva a

una matriz de transición $S = \begin{bmatrix} \cos(\theta) & -\sin(\theta) \\ \sin(\theta) & \cos(\theta) \end{bmatrix}$



$x^T S^T$

$$x^T A x = (S \tilde{x})^T A (S \tilde{x}) = \tilde{x}^T (S^T A S) \tilde{x} \Rightarrow x^T A x = \lambda_1 x_1^2 + \lambda_2 x_2^2$$

$S S^{-1} = S S^T$

Obs.: S resulta una matriz ortogonal, $S^T A S = S^{-1} A S =$

$$\begin{bmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{bmatrix} = D$$

Autovalores y Autovectores: definición

Sea $A \in \mathbb{K}^{n \times n}$, \mathbb{R} o \mathbb{C} diremos que $\lambda \in \mathbb{K}$ es un **autovalor** (ava) de A y $x \in \mathbb{K}^n$, $x \neq 0$ es un **autovector** (ave) asociado a λ si:

$$\underbrace{Ax = \lambda x}_{\text{nx1} = \text{nx1}}$$



→ **Interpretación geométrica:** A cada vector que se encuentre en la dirección de x , la transformación $T(x) = Ax$ lo contrae (o expande) por un factor λ .

$$0 < \lambda < 1 \quad \xrightarrow{\text{se contrae}} \quad \lambda > 1 \quad \xrightarrow{\text{se expande}}$$

Importante: un autovalor puede ser nulo, un autovector no.

Resolución $Ax - x = 0$

$$(A - \underbrace{\lambda I}_{\text{n} \times \text{n}}) \underbrace{x}_{\text{nx1}} = 0$$
$$\underbrace{(A - \lambda I)}_{M} \underbrace{x}_{\text{nx1}} = 0$$

Queremos que el sist. tenga solución que sea compatible indeterminado

Sist. de ec. con n cc. y $n+1$ incógnitas

seguro es solución $x = 0$

$$\det M = 0$$

y NO aporta información

Autovalores y Autovectores: algunas aplicaciones

- ① Geometría: curvas planas o superficies.
- ② Sistemas dinámicos.
- ③ Análisis del comportamiento de sistemas de ecuaciones diferenciales.
- ④ Análisis de estabilidad.
- ⑤ Cadenas de Markov.
- ⑥ Grafos.
- ⑦ Reducción de dimensiones.
- ⑧ Cálculo de resonancias del sistema.
- ⑨ PageRank.

Hallando los autovalores

Dada $A \in \mathbb{K}^{n \times n}$, \mathbb{R} o \mathbb{C} , $\lambda \in \mathbb{K}$ es un autovalor de A si λ es un cero del polinomio característico, $p(\lambda)$, de A :

$$p(\lambda) = \det(A - \lambda I)$$

$$p(\lambda) = (\lambda - 1)^2 = 0$$

$\lambda = 1$
tene multiplicidad 2

Observación: Puede ocurrir que algún λ sea raíz múltiple de $p(\lambda)$.

Se llama **multiplicidad algebraica**, m_a , a la cantidad de veces que λ aparece como raíz.

$$\underline{m_a = 2}, \lambda = 1$$

Se llama **multiplicidad geométrica**, m_g , del autovalor λ , a la cantidad de autovectores l.i. asociados a λ .

$$m_a \geq m_g \geq 1$$

Propiedades de los autovectores

Dada $A \in \mathbb{K}^{n \times n}$, el conjunto de todos los autovectores asociados al autovalor λ generan un subespacio de \mathbb{K}^n (**autoespacio** de A respecto de λ). El conjunto de todos los autovectores de A se llama **autoespectro**.

$\det(A - \lambda I)$ tiene que ser cuadrada

Si λ es un autovalor de $A \in \mathbb{K}^{n \times n}$, el autoespacio E_λ asociado es la solución al sistema homogéneo $(A - \lambda I)x = 0$.

Teorema: Los autovectores x_1, \dots, x_n de una matriz $A \in \mathbb{R}^{n \times n}$ con n autovalores distintos de $\lambda_1, \dots, \lambda_n$ son linealmente independientes. Es decir, forman una base de \mathbb{R}^n .

Importante
ahorro de cálculos $p(\lambda)$ puede tener raíces \mathbb{R} ó \mathbb{C}

$$P(\lambda) = \lambda^2 + 1 = 0$$

Teorema: Si $A \in \mathbb{R}^{n \times n}$ es simétrica, entonces existe una base ortonormal correspondiente a un espacio vectorial formado por autovectores de A y además $\lambda_i \in \mathbb{R}, \forall i = 1, \dots, n$.

Ejemplo

Sea $A = \begin{bmatrix} 2 & -3 \\ 2 & -5 \end{bmatrix}$, calculamos $\det(A - \lambda I) = 0$, $\begin{pmatrix} 2 & -3 \\ 2 & -5 \end{pmatrix} - \begin{pmatrix} \lambda & 0 \\ 0 & \lambda \end{pmatrix}$

$$\begin{vmatrix} 2-\lambda & -3 \\ 2 & -5-\lambda \end{vmatrix} = (2-\lambda)(-5-\lambda) - 2 \cdot (-3) = -10 - 2\lambda + 5\lambda + \lambda^2 + 6 = \lambda^2 + 3\lambda - 4 = 0 \Leftrightarrow \lambda_1 = 1, \lambda_2 = -4 \quad \text{Autovesp. } \{1, -4\} \quad \text{son distintos}$$

• Buscamos $E_{\lambda=1}$, $\begin{pmatrix} 2 & -3 \\ 2 & -5 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = 1 \begin{pmatrix} x \\ y \end{pmatrix} \rightarrow \begin{cases} 2x - 3y = x \\ 2x - 5y = y \end{cases} \quad Ax = \lambda x$

ó equiv. $\begin{pmatrix} 1 & -3 \\ 2 & -6 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$

$$\begin{aligned} x - 3y &= 0 \\ x &= 3y \end{aligned} \quad 2x - 6y = 0 \quad y \text{ libre}$$

$$E_{\lambda=1} = \left\{ \begin{pmatrix} x \\ y \end{pmatrix} \in \mathbb{R}^2 : x = 3y \right\} = \text{gen} \left\{ \begin{pmatrix} 3 \\ 1 \end{pmatrix} \right\}$$

• Buscamos $E_{\lambda=-4}$, $\begin{pmatrix} 6 & -3 \\ 2 & -1 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$

$$\begin{aligned} 2x - y &= 0 \\ y &= 2x \quad x \text{ libre} \end{aligned} \quad E_{\lambda=-4} = \text{gen} \left\{ \begin{pmatrix} 1 \\ 2 \end{pmatrix} \right\}$$

Puedo definir $S = \begin{bmatrix} 3 & 1 \\ 1 & 2 \end{bmatrix}$

$$S^{-1} = \frac{1}{|S|} \begin{bmatrix} a_{22} - a_{12} \\ a_{11} - a_{21} \end{bmatrix}$$

ave λ_1 ave λ_2

$$S^{-1} A S = D = \begin{bmatrix} 1 & 0 \\ 0 & -4 \end{bmatrix}$$

$$(A = SDS^{-1})$$

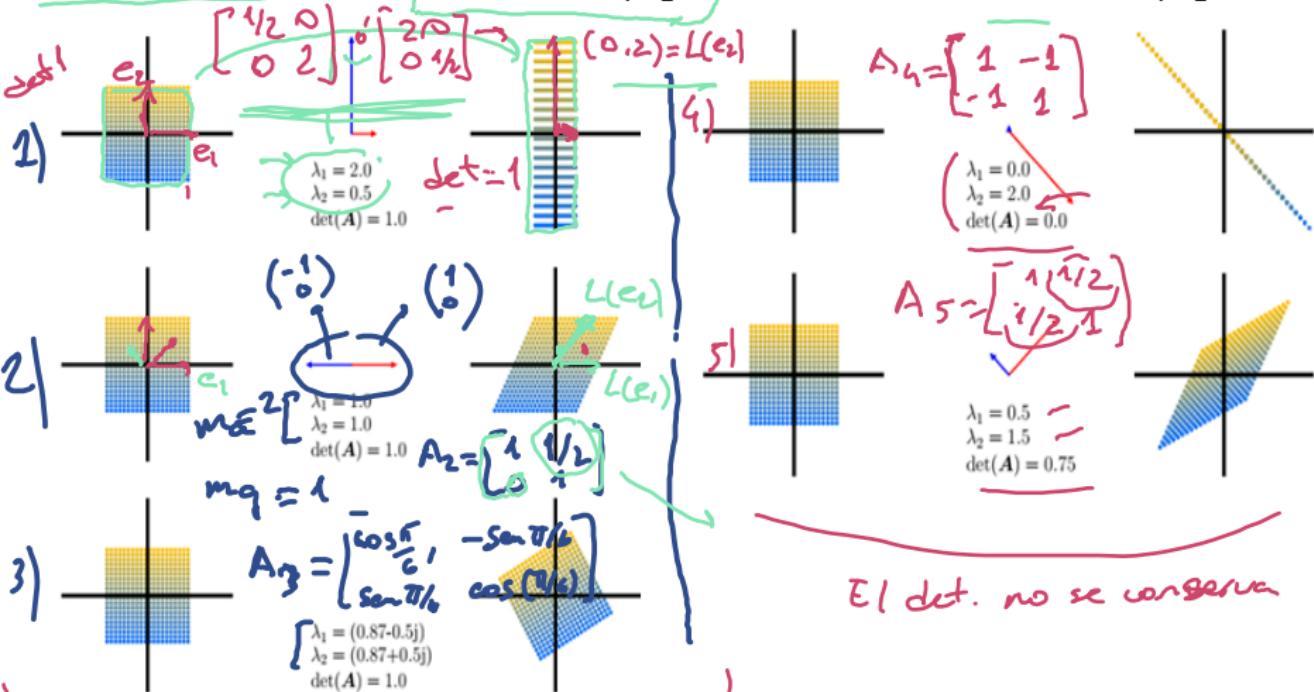
4 diagonal

Importante
el orden
de los autovalores

Interpretación gráfica (Mathematics for Machine Learning)

Propiedades

Sea $A \in \mathbb{K}^{n \times n}$: Área: $\det(A) = \prod_{i=1}^n \lambda_i$ y Perímetro: $Tr(A) = \sum_{i=1}^n \lambda_i$



det en todos los casos se conserva

Diagonalización

Diagonalización

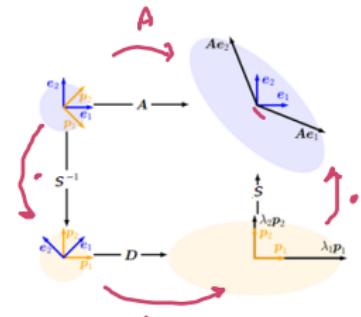
Definición:

Una matriz $A \in \mathbb{K}^{n \times n}$ es diagonalizable si $\exists S \in \mathbb{K}^{n \times n}$ no singular (es decir, tiene inversa) tal que:

$$S^{-1}AS = D \rightarrow AS = SD$$

donde D es una matriz *diagonal*.

Teorema: Sea $A \in \mathbb{K}^{n \times n}$ es diagonalizable si A tiene n autovectores linealmente independientes.



Conclusiones para $A \in \mathbb{K}^{n \times n}$

- ① A es diagonalizable \Rightarrow los vectores columna de la matriz de diagonalización S son los autovectores de A y los elementos de D son los autovalores de A . *respectando un orden.*
- ② B no es única, se pueden reordenar columnas, etc $\Rightarrow D$ será distinta.
- ③ A tiene n autovalores distintos \Rightarrow los autovectores correspondientes son l.i. $\Rightarrow A$ es diagonalizable.
- ④ A tiene menos de n autovectores l.i. $\Rightarrow A$ no es diagonalizable.
- ⑤ Si hay autovalores repetidos y si:
 - $m_a = m_g$ (en los ava repetidos) \Rightarrow los ave son l.i.
 - $m_a > m_g$ (en un ava repetido) $\Rightarrow A$ no es diagonalizable.
→ equivale a simétrica en \mathbb{R}
- ⑥ Si $A \in \mathbb{C}^{n \times n}$ es una matriz hermítica ($A = A^T = A^H$) $\Rightarrow A$ es diagonalizable y las columnas forman una BON.

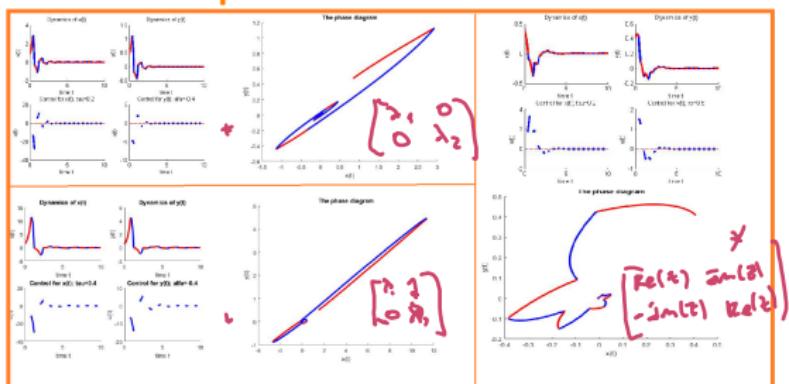
Matrices en bloques de Jordan

Sea $L : \mathbb{V} \rightarrow \mathbb{V}$ endomorfismo sobre \mathbb{K} – e.v. con $\dim(\mathbb{V}) = n$. Si $p(\lambda)$ se factoriza en \mathbb{K} entonces existe una base que viene dada por la matriz en bloques ($m < n$).

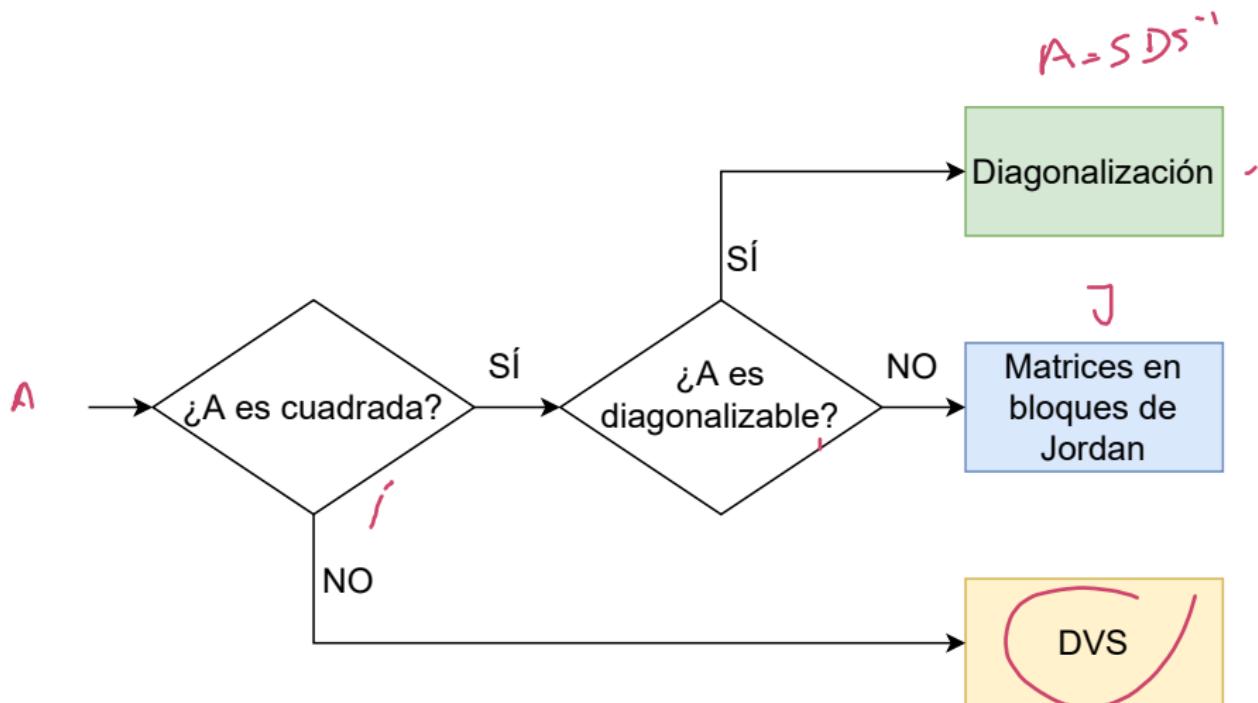
$$J = \begin{bmatrix} A_1 & & & & 0 & & \\ 0 & \ddots & & & & & \\ & & \ddots & & & & \\ & & & \ddots & & & \\ 0 & & & & \ddots & & \\ & & & & & A_m & \end{bmatrix} \in \mathbb{K}^{n \times n} \quad A_k = \begin{bmatrix} \lambda_k & 1 & 0 & \dots & 0 \\ 0 & \ddots & & & \\ & & \ddots & & \\ & & & \ddots & \\ 0 & & & & 1 \end{bmatrix}, \sum_{k=1}^m \lambda_k = n.$$

Obs.: Cuando es diagonalizable $m = n$.

Aplicación en Control



¿Qué puede pasar al intentar diagonalizar?



Descomposición en Valores Singulares (DVS)

¿Qué pasa cuando A no es cuadrada?

$\mathbb{R}^{m \times n}$

simétrica

Teorema: Dada $A \in \mathbb{C}^{m \times n}$, siempre se puede obtener una matriz hermítica, semidefinida positiva $S \in \mathbb{C}^{n \times n}$ como:

$$S \doteq A^H A$$

$$S = A^T A$$

S es siempre (herm o simétrica)

$$\text{En } \mathbb{R}, S = S^T$$

$$S = A^T A \Rightarrow S^T = (A^T A)^T = A^T (A^T)^T = A^T A = S$$

Obs.: $\tilde{S} \in \mathbb{C}^{m \times m}$ definida como $\tilde{S} \doteq A A^H$ también resulta hermítica y semidefinida positiva.

Obs. (II): Como S, \tilde{S} son semidef. positivas, todos sus autovalores son reales **no negativos**.

$$\begin{bmatrix} \lambda_1 & \\ & \lambda_2 \end{bmatrix} \begin{bmatrix} \lambda_1 & \\ & \lambda_2 \end{bmatrix} \rightarrow \begin{array}{c} \lambda_1^2 \\ - \\ \lambda_2^2 \end{array}$$

DVS: Definición

Teorema: Sea $A \in \mathbb{R}^{m \times n}$ una matriz de rango $r \in \{0, \dots, \min\{m, n\}\}$. La descomposición en valores singulares (DVS, SVD en inglés) de A se define como:

$$A = U \cdot \Sigma \cdot V^T$$

saint la diagonal.

$m \times n$ $m \times m$ $m \times n$ $n \times n$

$(m \times n)$ $(n \times m)$

donde:

- $U \in \mathbb{R}^{m \times m}$ es la matriz ortogonal formada por los aves de AA^T .
- $\Sigma \in \mathbb{R}^{m \times n}$ es la matriz "diagonal" de valores singulares $\sigma_i = \sqrt{\lambda_i}$, con λ_i los primeros $p = \min\{m, n\}$ aves de AA^T y A^TA .
- $V \in \mathbb{R}^{n \times n}$ es la matriz ortogonal formada por los aves de A^TA .

$$\begin{matrix} n \\ m \end{matrix} \boxed{A} = \begin{matrix} m \\ m \end{matrix} \boxed{U} \begin{matrix} n \\ m \end{matrix} \boxed{\Sigma} \begin{matrix} n \\ n \end{matrix} \boxed{V^T} \approx$$

Ejemplo: Hallar una DVS

Sea $A = \begin{pmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$ Calculamos $A^T A = \begin{pmatrix} 1 & 0 \\ 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} = \begin{pmatrix} 1 & 1 & 0 \\ 1 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$

- 1) Observemos que $A^T A$ la puedo ver con 2 bloques $\Rightarrow \lambda_1 = 1$ es un λ v.a
- 2) Como $A^T A$ tiene 2 filas iguales $\Rightarrow \det(A^T A) = 0 \Rightarrow \lambda_2 = 0$ e un λ v.a
- 3) Ya tenemos $\lambda_1 = 1$, $\lambda_2 = 0$ y sabemos que $\lambda_1 + \lambda_2 + \lambda_3 = \text{tr}(A) = 3$
entonces $\lambda_3 = 2$
- 4) Ahora buscamos los autoespacios asociados a $\lambda_1 = 1$, nos da:
 $E_0 = \text{gen} \left\{ \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} \right\}; E_1 = \text{gen} \left\{ \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix} \right\} \text{ y } E_2 = \text{gen} \left\{ \begin{pmatrix} -1 \\ 1 \\ 0 \end{pmatrix} \right\}$
- 5) Como los avs provienen de una matriz simétrica, son l.i. Además por ser $A^T A$ simétrica los avs son ortogonales, entonces si normalizamos podemos construir $V^T = \begin{bmatrix} -1/\sqrt{2} & 1/\sqrt{2} & 0 \\ 1/\sqrt{2} & 1/\sqrt{2} & 0 \\ 0 & 0 & 1 \end{bmatrix}$ con $\Sigma = \begin{bmatrix} \sqrt{2} & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix}$
- 6) Análogo para $A A^T$ tiene una 2 y 1
y finalmente, verificar $A = U \Sigma V^T$

DVS Compacta, Reducida y Truncada

Sea $A \in \mathbb{R}^{m \times n}$ con DVS $A = U\Sigma V^T$:

$$\begin{matrix} m \times n \\ \begin{array}{|c|c|c|} \hline \cdot & \cdot & \cdot \\ \hline \cdot & \cdot & \cdot \\ \hline \cdot & \cdot & \cdot \\ \hline \end{array} \end{matrix} = \begin{matrix} m \times m \\ \begin{array}{|c|c|} \hline \text{blue} & \text{green} \\ \hline \end{array} \end{matrix} \cdot \begin{matrix} m \times n \\ \begin{array}{|c|c|c|c|} \hline \sigma_1 & 0 & 0 & 0 \\ \hline 0 & \sigma_2 & 0 & 0 \\ \hline 0 & 0 & \sigma_3 & 0 \\ \hline 0 & 0 & 0 & 0 \\ \hline \end{array} \end{matrix} \cdot \begin{matrix} n \times n \\ \begin{array}{|c|c|c|c|} \hline \text{purple} & \text{orange} & \text{yellow} & \text{cyan} \\ \hline \end{array} \end{matrix}$$

→ Si es cuadrada

- Si $p = \min\{m, n\}$, la DVS compacta es $A = U_p \Sigma_p V_p^T$

$$\begin{matrix} p \times n \\ \begin{array}{|c|c|c|c|} \hline \cdot & \cdot & \cdot & \cdot \\ \hline \cdot & \cdot & \cdot & \cdot \\ \hline \cdot & \cdot & \cdot & \cdot \\ \hline \cdot & \cdot & \cdot & \cdot \\ \hline \cdot & \cdot & \cdot & \cdot \\ \hline \end{array} \end{matrix} = \begin{matrix} p \times p \\ \begin{array}{|c|c|} \hline \text{blue} & \text{green} \\ \hline \end{array} \end{matrix} \cdot \begin{matrix} p \times p \\ \begin{array}{|c|c|c|c|} \hline \sigma_1 & 0 & 0 & 0 \\ \hline 0 & \sigma_2 & 0 & 0 \\ \hline 0 & 0 & \sigma_3 & 0 \\ \hline 0 & 0 & 0 & 0 \\ \hline \end{array} \end{matrix} \cdot \begin{matrix} p \times n \\ \begin{array}{|c|c|c|c|} \hline \text{red} & \text{orange} & \text{yellow} & \text{cyan} \\ \hline \end{array} \end{matrix}$$

→ saco 0's
→ si la volvemos, NO guardo ceros

- Si $\sigma_1, \dots, \sigma_r > 0, \sigma_{r+1}, \dots, \sigma_p = 0$, la DVS reducida es $A = U_r \Sigma_r V_r^T$

$$\begin{matrix} m \times n \\ \begin{array}{|c|c|c|c|} \hline \cdot & \cdot & \cdot & \cdot \\ \hline \cdot & \cdot & \cdot & \cdot \\ \hline \cdot & \cdot & \cdot & \cdot \\ \hline \cdot & \cdot & \cdot & \cdot \\ \hline \cdot & \cdot & \cdot & \cdot \\ \hline \end{array} \end{matrix} = \begin{matrix} m \times r \\ \begin{array}{|c|c|} \hline \text{blue} & \text{red} \\ \hline \end{array} \end{matrix} \cdot \begin{matrix} r \times r \\ \begin{array}{|c|c|c|c|} \hline \sigma_1 & 0 & 0 & 0 \\ \hline 0 & \sigma_2 & 0 & 0 \\ \hline 0 & 0 & \sigma_3 & 0 \\ \hline 0 & 0 & 0 & 0 \\ \hline \end{array} \end{matrix} \cdot \begin{matrix} r \times n \\ \begin{array}{|c|c|c|c|} \hline \text{purple} & \text{pink} & \text{dark blue} & \text{black} \\ \hline \end{array} \end{matrix}$$

Lo rojo no lo guardo, son ceros.
 $\sigma_3 = 0$

- Sea $k \in \{1, \dots, r - 1\}$, la DVS truncada es $A \approx U_k \Sigma_k V_k^T$

$\sigma_1 \gg \sigma_7$ (por ej.)
puedo despreciar σ_7
y los que sigan

$$\begin{matrix} m \times n \\ \begin{array}{|c|c|c|c|} \hline \cdot & \cdot & \cdot & \cdot \\ \hline \cdot & \cdot & \cdot & \cdot \\ \hline \cdot & \cdot & \cdot & \cdot \\ \hline \cdot & \cdot & \cdot & \cdot \\ \hline \cdot & \cdot & \cdot & \cdot \\ \hline \end{array} \end{matrix} \approx \begin{matrix} m \times k \\ \begin{array}{|c|c|} \hline \text{red} \\ \hline \end{array} \end{matrix} \cdot \begin{matrix} k \times k \\ \begin{array}{|c|c|c|c|} \hline \sigma_1 & 0 & 0 & 0 \\ \hline 0 & \sigma_2 & 0 & 0 \\ \hline 0 & 0 & \sigma_3 & 0 \\ \hline 0 & 0 & 0 & 0 \\ \hline \end{array} \end{matrix} \cdot \begin{matrix} k \times n \\ \begin{array}{|c|c|c|c|} \hline \text{red} & \text{black} \\ \hline \end{array} \end{matrix}$$

→ aproximación.

Pseudoinversa de Moore-Penrose

Sea $A \in \mathbb{R}^{m \times n}$ y el sistema lineal $Ax = y$. La inversa de A no está definida, pero si $m > n$ una posible solución (cuadrados mínimos) era

$$\hat{x} = (A^T A)^{-1} A^T y$$

¿Pero qué ocurre si $A^T A$ no es invertible? Se define la pseudoinversa de Moore-Penrose como

$$A^\dagger = V_r \Sigma_r^{-1} U_r^T$$

y $\hat{x} = \underline{A^\dagger y}$ es (si $m < n$) la solución de mínima norma euclídea o (si $m > n$) la aproximación de mínimo error cuadrático/distancia euclídea.

Obs.: Todo lo anteriormente visto también vale para $A \in \mathbb{C}^{m \times n}$, utilizando \cdot^H en vez de \cdot^T . Se utilizaron matrices reales para facilitar la lectura.

Una aplicación obvia para la DVS es, como vimos recién, la "solución" de sistemas de ecuaciones para los cuales el método de cuadrados mínimos no es factible.

¿Pero es ese el único uso que le podemos dar? Las descomposiciones siempre nos brindan un criterio bajo el cual obtener la *mejor* aproximación de *orden k* para el objeto a descomponer, y eso podría llegar a ser muy útil.