


# Clase 7: Optimización

Verónica Pastor, Martín Errázquin

Análisis Matemático para Inteligencia Artificial



2/12/2022

# Ramas Principales de la Optimización



## Optimización con restricciones

Análisis I



$f(b) < f(c)$   
en  $c$  hay  
máx abs.

$\text{Dom } f = [a, b] \rightarrow$  convexo (cerrado y acut)

# Optimización con restricciones de igualdad

Dado el problema de optimización con restricciones:

*función objetivo*

$$\begin{aligned} & \underset{\text{opt}}{f(x_1, \dots, x_n)} \\ \text{s.a. } & g_1(x_1, \dots, x_n) = 0 \\ & \vdots \\ & g_m(x_1, \dots, x_n) = 0 \end{aligned}$$

*de restricciones*

*Todas las funciones en el mismo e.v.  
(1)  $f, g_i$*

donde  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  y  $g_i : \mathbb{R}^n \rightarrow \mathbb{R}$  con  $i = 1, \dots, m$ .

Se denomina **función Langrangiana** a la función de  $n + m$  variables  $\mathcal{L}$  definida por:

$$\mathcal{L}(\bar{\lambda}, \bar{x}) = f(\bar{x}) + \lambda_1 g_1(\bar{x}) + \dots + \lambda_m g_m(\bar{x}), \quad \text{con } \bar{\lambda} = (\lambda_1, \dots, \lambda_m)$$
$$f(\bar{x}) + \bar{\lambda} \left( \begin{matrix} ? \\ \vdots \\ ? \end{matrix} \right) = f(\bar{x}) + \left( \begin{matrix} \lambda_1, \dots, \lambda_m \\ \vdots \\ \lambda_m \end{matrix} \right) \left( \begin{matrix} ? \\ \vdots \\ ? \end{matrix} \right)$$

# Teorema de condición necesaria de Lagrange

Sea  $D \subseteq \mathbb{R}^n$  abierto. Sea (1) con  $m < n$ , donde  $f, g_i, i = 1, m$  son funciones definidas de  $D$  en  $\mathbb{R}$ , con derivadas parciales primeras continuas en  $D$  y

$f, g_i \in C^1$

$$B = \{\bar{x} \in D : g_i(\bar{x}) = 0, i = 1, m\}$$

el conjunto de soluciones factibles.

Entonces, si  $\bar{x}$  es un óptimo local de (1) tal que la matriz jacobiana de  $\bar{g}(\bar{x}^*)$  tal que  $|J\bar{g}(\bar{x}^*)_m| \neq 0$ , existen  $m$  números reales  $\lambda_1^*, \dots, \lambda_m^*$  tales que son solución del sistema:

$$\begin{aligned} L(\bar{\lambda}, \bar{x}) &= \\ f(\bar{x}) + \sum_{i=1, m} g_i(\bar{x}) \end{aligned}$$

$$\nabla f(\bar{x}^*) + \sum_{i=1, m} \lambda_i^* \nabla g_i(\bar{x}^*) = \bar{0}$$

$$|J\bar{g}| = \begin{vmatrix} \nabla g_1 \\ \vdots \\ \nabla g_m \end{vmatrix} \neq 0$$

los  $\nabla g_i$  son l.i.

Las soluciones factibles que verifican esta ecuación se denominan *puntos estacionarios*.

Los números  $\lambda_1, \dots, \lambda_m$  se denominan *multiplicadores de Langrange* asociados a las  $m$  restricciones en el punto  $\bar{x}^*$ .

# Ejemplo

opt función objetivo

$$C_1: x_1^2 + 2x_2 = k \rightarrow x_2 = -\frac{x_1^2}{2} + \frac{k}{2}$$

$$\min f(x_1, x_2) = x_1^2 + 2x_2$$


$f: \mathbb{R}^2 \rightarrow \mathbb{R}$

$$\text{graf}(f) \subset \mathbb{R}^3 \quad \text{s.a. } x_1 + x_2 = 1 \quad \text{rcuta}$$

definimos

Así definimos:

$$g(x_1, x_2) = x_1 + x_2 - 1. \quad (S_1(x_1, x_2) = 0)$$



- El conjunto de soluciones factibles es la recta  $x_2 = -x_1 + 1$ .
- Las curvas de nivel de la función  $f(x_1, x_2) = x_1^2 + 2x_2$  son paráboles de la forma  $x_1^2 + 2x_2 = k, k \in \mathbb{R}$ .  $\nabla f(\bar{x}, \bar{y}) = f(\bar{x}) + \lambda \nabla g(\bar{x})$

$$\therefore \bar{x}^* = (1, 0) \text{ y } f(\bar{x}^*) = 1.$$

dervio  $\nabla f(x_1, x_2) + \lambda \nabla g(x_1, x_2) = 0$

$$\left( \frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2} \right) + \lambda \left( \frac{\partial g}{\partial x_1}, \frac{\partial g}{\partial x_2} \right) = 0$$

Calculamos los vectores gradientes:  $\nabla f(x_1, x_2) = (2x_1, 2)$  y

$\nabla g(x_1, x_2) = (1, 1)$ , ambos vectores son l.d. en  $\bar{x}^*$ :

$$(2x_1, 2) + \lambda(1, 1) = (0, 0) \Rightarrow \begin{cases} 2x_1 + 2 = 0 \\ 2 + \lambda = 0 \end{cases} \Rightarrow \lambda = -2 \Rightarrow x_1 = 1$$

# Optimización con restricciones de desigualdad

## Condiciones necesarias de primer orden de Fritz-John

Dado el problema de optimización con restricciones:

$$\begin{array}{l} \text{opt } f(x_1, \dots, x_n) \\ \text{s.a. } g_1(x_1, \dots, x_n) \leq 0 \\ \quad \vdots \\ g_m(x_1, \dots, x_n) \leq 0 \end{array} \quad (2)$$

donde  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  y  $g_i : \mathbb{R}^n \rightarrow \mathbb{R}$  con  $i = 1, \dots, m$ . Sea  $\bar{x}^*$  un punto tal que  $I = \{i ; g_i(\bar{x}^*) = 0\}$ ,  $f, g_i$  diferenciables en  $\bar{x}^*$ . Entonces, si  $g_i, i \notin I$  son continuas en  $\bar{x}^*$  se verifica que es solución y existen escalares  $\lambda_0, \lambda_i, i \in I$  no todos nulos tales que:

$$\lambda_0 \nabla f(\bar{x}^*) + \sum_{i=1, m} \lambda_i \nabla g_i(\bar{x}^*) = \bar{0}$$

para  $0 \leq \lambda_0, \lambda_i, i \in I$ , y  $g_i(\bar{x}^*) \leq 0, i = 1, m$ .

# Dualidad en Optimización: Problema dual

Dado el problema primal:

$$\begin{aligned} & \min f(\underbrace{x_1, \dots, x_n}_{\in \mathbb{R}^n}) \\ \text{s.a. } & g(x_1, \dots, x_n) \leq b \\ & x_i \geq 0 \end{aligned}$$

Tenemos el problema dual:

$$\begin{aligned} & \max D(\underbrace{y_1, \dots, y_m}_{\in \mathbb{R}^m}) \\ \text{s.a. } & h(y_1, \dots, y_m) \geq b \\ & y_j \leq 0 \end{aligned}$$


- Si  $\bar{x}^*$  es una solución factible del problema primal e  $\bar{y}^*$  es una solución del dual entonces  $f(\bar{x}^*) \geq D(\bar{y}^*)$  → estoy encontrando una cota
- Si un problema no tiene un óptimo finito entonces el otro no es factible.

# Función Convexa

Def: Un subconjunto  $S \subset \mathbb{R}^n$  es **convexo** si para cada par de puntos  $x, y \in S, \alpha \in [0, 1]$  se verifica que  $\underline{z = \alpha x + (1 - \alpha)y \in S}$ .

Obs:  $X_1, X_2$  son dos conjuntos convexos, entonces,

- $X_1 \cap X_2$  es convexo.
- $\underline{X_1 + X_2 = \{x_1 + x_2 \in \mathbb{R}^n : x_1 \in X_1, x_2 \in X_2\}}$ .
- si  $L$  es una transformación lineal,  $L(X_1)$  es convexa.



## Función Convexa

Def: Sea  $M \subset \mathbb{R}^n, M \neq \emptyset$  convexo,  $f : M \rightarrow \mathbb{R}$ . Entonces se dice que:

- $f$  es convexa en  $M$  sii  $\forall x, y \in M, \forall \alpha \in [0, 1]$  se verifica que:

$$f(\underline{\alpha x + (1 - \alpha)y}) \leq \underline{\alpha f(x) + (1 - \alpha)f(y)}$$

Desig.

## Desigualdad de Jensen

- $f$  es estrictamente convexa en  $M$  sii  $\forall x, y \in M, \forall \alpha \in (0, 1)$  se verifica que:

$$f(\underline{\alpha x + (1 - \alpha)y}) < \underline{\alpha f(x) + (1 - \alpha)f(y)}$$

# Condiciones para convexidad de funciones diferenciables

Sea  $M \subset \mathbb{R}^n$ ,  $M \neq \emptyset$  abierto convexo,  $f : M \rightarrow \mathbb{R}$  diferenciable, se dice que:

$f$  es convexa en  $M \Leftrightarrow \forall x, y \in M, f(y) \geq f(x) + \underline{\nabla f(x)}(y - x)$

O bien,  $(\nabla f(y) - \nabla f(x))(y - x) \geq 0$

análogo en forma matricial.

similar a la aproximación  
diferenciable

Prop: Sea  $M \subset \mathbb{R}^n$ ,  $M \neq \emptyset$  abierto convexo,  $f : M \rightarrow \mathbb{R}$ ,  $f \in C^2$ . Entonces,

$f$  es convexa en  $M$  si  $\forall x \in M, y^T Hf(x)y \geq 0$  para cualquier  $y \in \mathbb{R}^n$ .

## Condiciones Suficientes de Optimalidad Global

Matriz

Hessiana

$$\frac{\partial f}{\partial x_i} = \frac{\partial f}{\partial y_j} \times s: f \in C^2$$

es decir, es simétrica

forma cuadrática.

$$\begin{aligned} & \text{opt } f(x_1, \dots, x_n) \\ & \text{s.a. } g_1(x_1, \dots, x_n) = 0 \end{aligned}$$

:

$$g_m(x_1, \dots, x_n) = 0$$

Aprox. lineal

$$f(x) \approx f(x_0) + f'(x_0)(x - x_0)$$

función      recta tang.

con  $m < n$  donde  $f$  y  $g_i, i = 1, \dots, m$  son funciones  $C^1$  en un conjunto abierto  $D \subset \mathbb{R}^n$ . Entonces se verifica que si  $f$  es convexa en el conjunto de soluciones factibles  $B$  y, las funciones  $g_i$  son lineales, todos los puntos estacionarios son mínimos globales.

# Programación Lineal

Un problema de programación lineal es donde tanto la función objetivo como las funciones que definen las restricciones son lineales. La forma general es:

$$\underset{\text{opt}}{\underbrace{c_1x_1 + \dots + c_nx_n}} \rightarrow f \text{ función objetivo}$$
$$\leq b_0$$

$$\text{s.a. } \underbrace{a_{11}x_1 + \dots + a_{1n}x_n}_{\vdots} \leq b_1$$

$$a_{m1}x_1 + \dots + a_{mn}x_n \leq b_m$$

$$d_{11}x_1 + \dots + d_{1n}x_n \geq e_1$$

$$d_{r1}x_1 + \dots + d_{rn}x_n \geq e_r$$

$$g_{11}x_1 + \dots + g_{1n}x_n = b_1$$

$$g_{s1}x_1 + \dots + g_{sn}x_n = b_s$$

# Propiedades de la Programación Lineal



**Definición:** Sea  $S \subset \mathbb{R}^n$  convexo  $S \neq \emptyset$ ,  $\bar{x}^* \in S$  es un punto extremo de  $S$  si  $\bar{x}^*$  no puede expresarse como combinación lineal convexa de puntos de  $S$  distintos de él.

- ① Es un problema convexo ya sea de minimización o maximización.
- ② La solución óptima, si existe, es global.
- ③ Nunca existen óptimos locales que no sean globales.
- ④ Puede tener o no solución, en caso de existir se encuentra en único punto o en infinitos.

**Objetivo:** Se busca hallar  $\min \bar{c}\bar{x}$ , s.a.  $A\bar{x} = \bar{b}; \bar{x} \geqslant 0$ ,  
donde  $A \in \mathbb{R}^{m \times n}$ ,  $m < n$ ,  $rg(A) = m$ .

# Algoritmo del simplex

Iniciar: eligiendo una solución básica factible de una submatriz  $B$  de  $A$ ,  $|B| \neq 0$ . Iterar:

- 1 Resolver el sistema  $B\bar{x}_B = \bar{b}$ . Entonces la solución será  $\bar{x} = (\bar{x}_B, \bar{x}_N)$ .
- 2 Calcular  $Y = B^{-1}N$ , donde  $N \in \mathbb{R}^{m \times (n-m)}$  cuyas columnas corresponden a las soluciones no básicas. Hallar  $z_j = \bar{c}_B \bar{y}_j$ , donde  $\bar{c}_B$  son los coeficientes de la función objetivo asociados a la solución básica e  $\bar{y}_j$  es la columna de la matriz  $T$  correspondiente a  $x_j$ .  
Sea  $z_k - c_k = mx\{z_j - c_j, j \in J\}$  donde  $J$  los índices asociados a las variables no básicas.
  - Si  $z_k - c_k \leq 0$ , la solución básica factible es el óptimo del problema, que no será único si  $z_k - c_k = 0$
  - Si  $z_k - c_k > 0$  debemos seguir...
- 3 Antes de construir una nueva solución conviene ver si existe  $j \in J : z_k - c_k > 0, \bar{y}_j \leq 0$ . Si esto no sucede, terminamos ya que el problema carece de óptimo finito. Sino, construimos una nueva solución:

La variable  $x_k$  correspondiente al  $z_k - c_k$  máximo, será básica en la nueva solución y dejará de serlo  $x_l$ , cuando  $l$  sea el índice determinado por:

$$\frac{x_l}{y_{lk}} = \min\left\{\frac{x_i}{y_{ik}} : y_{ik} > 0\right\}$$

Actualizar la nueva submatriz  $B$  y volver a (1).

# Programación cuadrática

En el caso de que la función objetivo sea una cuadrática convexa:

$$\min_{x \in \mathbb{R}^d} \frac{1}{2} x^T Q x + c^T x$$

s.a:  $Ax \leq b$  donde  $A \in \mathbb{R}^{m \times d}$ ,  $b \in \mathbb{R}^m$ ,  $c \in \mathbb{R}^d$ .

La matriz  $Q \in \mathbb{R}^{d \times d}$  es simétrica y definida positiva, y por lo tanto la función objetivo es convexa. El lagrangiano está dado por:

$$L(x, \lambda) = \underbrace{\frac{1}{2} x^T Q x + c^T x}_{\text{Función objetivo}} + \underbrace{\lambda^T (Ax - b)}_{\text{Restricciones}}$$

Derivando respecto a  $x$ , y despejando:

$$(Qx) + (c + A^T \lambda) = 0 \Rightarrow x = -Q^{-1}(c + A^T \lambda)$$

Y sustituyendo obtenemos la lagrangiana dual:

$$D(\lambda) = -\frac{1}{2}(c + A^T \lambda)^T - Q^{-1}(c + A^T \lambda) - \lambda^T b.$$

# Convexo Conjugado

La transformada de Legendre-Fenchel es una transformación de una función convexa diferenciable  $f(x)$  a una función que depende de las tangentes  $s(x) = \nabla_x f(x)$ .

La transf. es una función de  $f$ , no depende de  $x$   
por eso se conoce como conjugada convexa

Se define el conjugado convexo de una función  $f : \mathbb{R}^D \rightarrow \mathbb{R}$  es una función  $f^*$  definida por:

$$f^*(s) = \sup_{x \in \mathbb{R}^D} (\langle x, s \rangle, f(x))$$

↳ se considera p.i  
estándar entre vectores  
de dim finita

# Librerías de Python para problemas de optimización

Citado de la página web: <https://relopezbriega.github.io/blog/2017/01/18/problemas-de-optimizacion-con-python/>

En Python podemos encontrar varias librerías que sirven para los problemas de optimización:

- CVXopt: Esta es una librería con una interface para resolver problemas de optimización convexa.
- PuLP: Esta librería proporciona un lenguaje para modelar y resolver problemas de optimización utilizando programación lineal.
- Pyomo: Tiene una notación similar a la que utilizaríamos en la definición matemática de los problemas.